

Khai phá dữ liệu văn bản y tế tiếng Việt: Mô hình phân loại đa nhiệm dựa trên kiến trúc KEHN

Knowledge-Enhanced Hierarchical Network
17 Chuyên khoa · 4 Ý định · 5 Loại Thực thể Y tế

Giảng viên hướng dẫn: **TS. Trần Thanh Phước**

Sinh viên thực hiện: **Phạm Hồng Đăng Khoa
Nguyễn Hoàng Khang**

Khoa Công nghệ Thông tin

Đại học Tôn Đức Thắng

Báo cáo Đồ án Cuối kỳ — 08/05/2026

Nội dung trình bày

- 1 Giới thiệu & Đặt vấn đề
- 2 Dữ liệu nghiên cứu
- 3 Kiến trúc Đề xuất (KEHN)
- 4 Chiến lược Huấn luyện (Curriculum Learning)
- 5 Kết quả Thực nghiệm & Thảo luận
- 6 Kết luận & Hướng phát triển

- 1 Giới thiệu & Đặt vấn đề
- 2 Dữ liệu nghiên cứu
- 3 Kiến trúc Đề xuất (KEHN)
- 4 Chiến lược Huấn luyện (Curriculum Learning)
- 5 Kết quả Thử nghiệm & Thảo luận
- 6 Kết luận & Hướng phát triển

Đặt vấn đề & Động lực nghiên cứu

Thực trạng:

- Bệnh nhân thường xuyên đặt câu hỏi y tế trực tuyến.
- Nhu cầu phân loại chuyên khoa chính xác, bóc tách thực thể (NER) và hiểu ý định (Intent).

Hạn chế của phương pháp cũ:

- Kiến trúc dạng đường ống (Pipeline): Topic → Intent → NER.
- Dễ gây ra *hiệu ứng lan truyền lỗi (error propagation)*.

Giải pháp đề xuất

Xây dựng kiến trúc **Joint Learning** (Học đồng thời) nhằm chia sẻ biểu diễn ngữ cảnh, giải quyết 3 bài toán NLU y tế trong một mô hình duy nhất.

Mô hình KEHN

Knowledge-Enhanced Hierarchical Network cho Tiếng Việt.

Mục tiêu nghiên cứu

Xây dựng một hệ thống NLU hợp nhất cho các câu hỏi y khoa Tiếng Việt, xử lý hiệu quả sự mất cân bằng lớp và tối ưu hoá đa nhiệm.

Các đóng góp nổi bật:

- **Kiến trúc KEHN:** Kết hợp PLM (PhoBERT/ViHealthBERT) + BiLSTM + Co-Interactive Transformer + Stack-Propagation.
- **Cơ chế giải mã NER:** Tích hợp CRF với ràng buộc chuyển tiếp BIO nhằm loại bỏ các chuỗi nhãn không hợp lệ.
- **Tối ưu hàm Loss:** Sử dụng Confidence-Weighted Loss để xử lý dữ liệu pseudo-labels (nhãn giả).
- **Curriculum Learning:** Chiến lược học theo giáo trình 4 giai đoạn lấy cảm hứng từ OneNet.

Mục lục

- 1 Giới thiệu & Đặt vấn đề
- 2 Dữ liệu nghiên cứu**
- 3 Kiến trúc Đề xuất (KEHN)
- 4 Chiến lược Huấn luyện (Curriculum Learning)
- 5 Kết quả Thử nghiệm & Thảo luận
- 6 Kết luận & Hướng phát triển

Tổng quan Tập dữ liệu Medical KEHN

Đặc trưng dữ liệu:

- **Nguồn:** ViMQ (8,444) + Dữ liệu Bệnh viện (9,946).
- **Tổng số mẫu:** 18,390 câu hỏi y tế.
- **Phân chia (Split):** 70% Train / 15% Val / 15% Test.

Thông kê không gian nhãn:

- **Topic (Chuyên khoa):** 17 lớp (Nhi khoa, Sản phụ khoa,...).
- **Intent (Ý định):** 4 lớp (Chẩn đoán, Điều trị, Mức độ, Nguyên nhân).
- **NER (Thực thể):** 5 loại thực thể (SYM, PRO, DUR, SEV, DRU) với lược đồ BIO (11 nhãn).


Thách thức Dữ liệu

- **Mất cân bằng lớp cực đoan:** Oncology có 300 mẫu, trong khi Pediatrics có hơn 3,013 mẫu.
- **Nhiều từ Pseudo-labels:** Dữ liệu bệnh viện dùng nhãn sinh tự động (độ tin cậy 0.8 – 0.95).


Mục lục

- 1 Giới thiệu & Đặt vấn đề
- 2 Dữ liệu nghiên cứu
- 3 Kiến trúc Đề xuất (KEHN)**
- 4 Chiến lược Huấn luyện (Curriculum Learning)
- 5 Kết quả Thực nghiệm & Thảo luận
- 6 Kết luận & Hướng phát triển

Kiến trúc Tổng thể KEHN



Tầng 1: Shared Context Encoder



Mục tiêu: Tạo biểu diễn không gian chung, giải quyết sự phụ thuộc xa (long-term dependencies).

- 1. Word Embedding:** Dùng PhoBERT / ViHealthBERT ánh xạ token x_i thành $e_i \in \mathbb{R}^d$.
- 2. Sequential Encoding:** Chuỗi vector đi qua mạng BiLSTM 2 chiều:


$$\vec{h}_i = \text{LSTM}_{fwd}(e_i, \vec{h}_{i-1})$$

$$\overleftarrow{h}_i = \text{LSTM}_{bwd}(e_i, \overleftarrow{h}_{i+1})$$

- 3. Contextual Representation:**

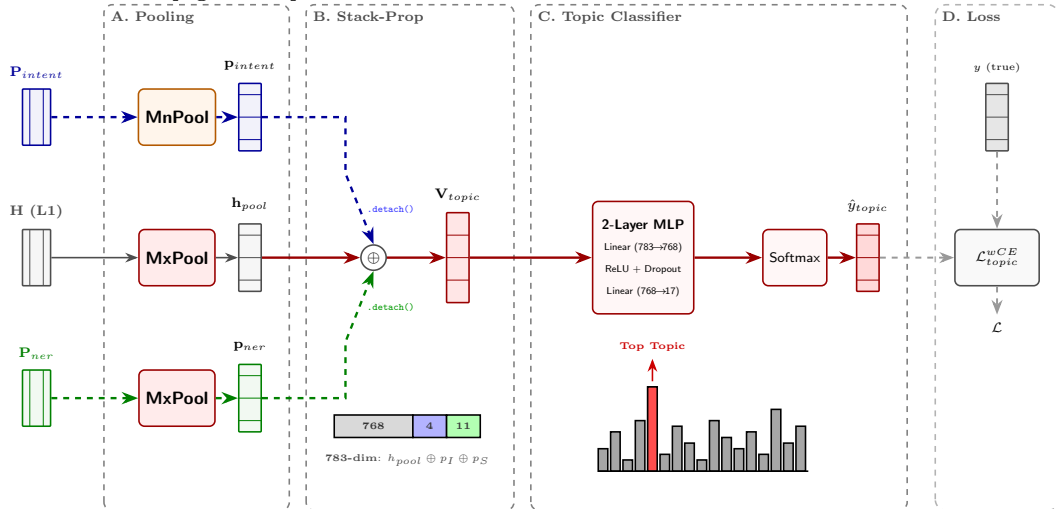
$$h_i = \vec{h}_i \oplus \overleftarrow{h}_i$$

Tầng 2: Co-Interactive Feature Mining



Tầng 3: Stack-Propagation Topic Decoder

Level 3: Stack-Propagation Topic Decoder



Mục lục

- 1 Giới thiệu & Đặt vấn đề
- 2 Dữ liệu nghiên cứu
- 3 Kiến trúc Đề xuất (KEHN)
- 4 Chiến lược Huấn luyện (Curriculum Learning)**
- 5 Kết quả Thực nghiệm & Thảo luận
- 6 Kết luận & Hướng phát triển

Triết lý chuyển đổi


Việc ép mô hình học 3 tác vụ khó ngay từ đầu làm nhiều không gian hàm Loss. KEHN áp dụng chiến lược học theo "Giáo trình" gồm 4 giai đoạn.

Giai đoạn (Phase)	Epoch	Trạng thái Module	Trọng số Loss (T/I/N)
1. topic_only	1 - 3	Đóng băng Tầng 2	1.0 / 0.0 / 0.0
2. mining_only	4 - 6	Đóng băng Tầng 3	0.1 / 1.0 / 1.0
3. joint_no_prop	7 - 10	Mở khóa toàn bộ	0.5 / 0.3 / 0.2
4. full_stack	11 - 30	Bật Stack-Propagation	0.5 / 0.3 / 0.2

Mục lục


- 1 Giới thiệu & Đặt vấn đề
- 2 Dữ liệu nghiên cứu
- 3 Kiến trúc Đề xuất (KEHN)
- 4 Chiến lược Huấn luyện (Curriculum Learning)
- 5 Kết quả Thực nghiệm & Thảo luận**
- 6 Kết luận & Hướng phát triển

So sánh Kết quả trên Tập Test (3 Backbones)



Quá trình Hội tụ (Training Dynamics)

Quá trình huấn luyện (Training History) qua các Epochs (3 Models)



Điểm mạnh của hệ thống

- **Đặc trưng chuyên ngành:** ViHealthBERT vượt trội chứng minh tầm quan trọng của Pre-training trên văn bản y tế Tiếng Việt.
- **Topic Classification:** Bài toán chính đạt Macro-F1 > 0.90 trên tất cả model, chứng minh tính hiệu quả của Stack-Propagation.

Hạn chế hiện tại (Bottleneck)

- **Hiệu năng NER:** Entity-F1 chỉ ở mức ~ 0.50 (Precision khá, nhưng Recall thấp), chủ yếu do nhiễu từ dữ liệu pseudo-labels.
- **Semantic Accuracy:** Mức 0.27 do đòi hỏi khắt khe (phải đúng tuyệt đối cả 3 bài toán trên cùng một câu).

Mục lục

- 1 Giới thiệu & Đặt vấn đề
- 2 Dữ liệu nghiên cứu
- 3 Kiến trúc Đề xuất (KEHN)
- 4 Chiến lược Huấn luyện (Curriculum Learning)
- 5 Kết quả Thử nghiệm & Thảo luận
- 6 Kết luận & Hướng phát triển**

- Đã đề xuất thành công mô hình **KEHN** cho Tiếng Việt, giải quyết đồng thời 3 bài toán y tế (Topic, Intent, NER).
- Việc áp dụng **CRF với ràng buộc BIO** và **Stack-Propagation** mang lại cấu trúc dự đoán vững chắc.
- Chiến lược **Curriculum Learning 4 giai đoạn** giúp hệ thống hội tụ ổn định bất chấp độ phức tạp của đa nhiệm.
- **ViHealthBERT** là backbone tối ưu nhất cho không gian từ vựng Y khoa Tiếng Việt.

Hướng phát triển tương lai

1. Cải thiện Recall cho NER bằng kỹ thuật Active Learning.
2. Tinh chỉnh siêu tham số (Curriculum boundaries, Loss weights).
3. Mở rộng bộ thực thể (vị trí giải phẫu, liều lượng thuốc).
4. Tích hợp mô hình vào pipeline Chatbot thực tế.